TAD: Traitement Automatique de Documents: APPLICATION à l'OCR ARABE

Projets à réaliser

Réglementation:

- 1. Les projets peuvent réalisés au minimum en binômes et un maximum de cinq étudiants.
- 2. Les projets peuvent être exposés devant l'ensemble des étudiants.
- 3. Le choix du projet est laissé libre aux étudiants.
- 4. Les projets avec les mêmes contenus se verront attribuer un 'zéro'.

Dates:

La date **limite** de remise des projets est prévue pour le vendredi 10/12/2021.

A remettre:

- 1. Un rapport format Word détaillant le travail effectué.
- 2. Un code source en python.
- 3. Une petite interface d'utilisation.
- 4. Une présentation format PowerPoint.

Intitulés:

- I. Filtrage, binarisation
 - 1. Réaliser une interface qui permet de choisir une suite de filtres pour un bon rendu de l'écriture.
 - 2. Proposer une technique adaptative interactive de binarisation de l'écriture.
- II. Linéarisation dans le domaine cartésien
 - 3. Segmentation de l'écriture arabe en parties connexes.
 - 4. Implémentation de l'algorithme de squelettisation « Zhang & Suen ».
 - 5. Proposer une technique de linéarisation de l'écriture : S'inspirer des directions de Freeman pour les directions à adopter.
- III. Linéarisation avec une structure d'arbres n-aires
 - 1. Segmentation de l'écriture arabe en parties connexes.
 - 2. Implémentation de l'algorithme de squelettisation « Zhang & Suen ».
 - 3. Représentation des parties connexes dans des structures d'arbres n-aires.
 - 4. Proposer une technique de linéarisation de l'écriture en utilisant la même structure : S'inspirer des directions de Freeman pour les directions à adopter.
- IV. Orthogonalisation dans le domaine cartésien
 - 1. Segmentation de l'écriture arabe en parties connexes.
 - 2. Implémentation de l'algorithme de squelettisation « Zhang & Suen ».

3. Proposer une technique d'orthogonalisation de l'écriture : on prend les deux directions horizontale et verticale.

V. Orthogonalisation

- 1. Segmentation de l'écriture arabe en parties connexes.
- 2. Implémentation de l'algorithme de squelettisation « Zhang & Suen ».
- 3. Représentation des parties connexes dans des structures d'arbres n-aires.
- 4. Proposer une technique d'orthogonalisation de l'écriture en utilisant la même structure : : on prend les deux directions horizontale et verticale.

VI. Segmentation

- 1. Proposer une technique de segmentation en parties connexes.
 - a. Appliquée à l'écriture contrainte
 - b. Appliquée à l'écriture non contrainte
- Séparer les parties principales des diacritiques et proposer une technique de segmentation en graphèmes avec affectation des diacritiques aux graphèmes appropriés.

VII. Extraction de caractéristiques

- 1. Implémenter trois méthodes d'extraction de caractéristiques.
- 2. Implémenter une méta-heuristique de votre choix pour sélectionner les caractéristiques de chaque méthode, puis appliquer la méta-heuristique pour les trois ensembles résultants.
- 3. Valider la méthode de sélection avec un classifieur de votre choix.

VIII. Extraction de caractéristiques

- 1. Implémenter trois méthodes d'extraction de caractéristiques.
- 2. Implémenter une méta-heuristique de votre choix pour sélectionner les caractéristiques de l'ensemble des trois méthodes, combinées de façon ordonnée, puis de façon aléatoire.
- 3. Valider la méthode de sélection avec un classifieur de votre choix.

IX. Combinaison de classifieurs

- 1. Choisir une méthode d'extraction de caractéristiques à implémenter.
- 2. Choisir trois classifieurs à utiliser.
- 3. Proposer une technique de combinaison de ces classifieurs.

X. Deep learning

- 1. Proposer une architecture de DL pour la reconnaissance du manuscrit arabe traitant une image de mot entier.
- 2. Étudier l'effet dequelques techniques d'augmentation des données

XI. Utilisation de Tesseract

- 1. Installation de Tesseract et Pythesseract
- 2. Configuration pour travailler avec la langue arabe

3. Utilisation de Python-OpenCV-Pytesseract pour reconnaître des images avec écriture arabe : imprimée, manuscrite contrainte, manuscrite non contrainte ?

XII. Utilisation de EasyOCR

- 1. Installation de EasyOCR
- 2. Configuration pour travailler avec la langue arabe
- 3. Utilisation de Python-OpenCV- EasyOCR pour reconnaître des images avec écriture arabe : imprimée, manuscrite contrainte, manuscrite non contrainte ?